

Deep Closest Point: Learning Representations for Point Cloud Registration.--ICCV'19

简介

本文以深度学习的方法重构经典的ICP算法，提出了名为DCP的算法，用于对两个点云之间的刚性变换进行基于深度学习的预测。

问题陈述

\mathcal{X}, \mathcal{Y} 代表两个点云, $\mathcal{X} = \{x_1, \dots, x_i, \dots, x_N\} \in \mathbb{R}^3, \mathcal{Y} = \{y_1, \dots, y_i, \dots, y_M\} \in \mathbb{R}^3$, 这里先假设 $M=N$, 并且本文的方法可以很轻松地被拓展到不相等的情况。假设 \mathcal{Y} 是由 \mathcal{X} 经过刚性变换得到的, 刚性变换为 $[R_{\mathcal{X}\mathcal{Y}}]$, $t_{\mathcal{X}\mathcal{Y}}$, 目标是最小化MSE: $E(R_{\mathcal{X}\mathcal{Y}}, t_{\mathcal{X}\mathcal{Y}}) = \frac{1}{N} \sum_i \|R_{\mathcal{X}\mathcal{Y}} x_i + t_{\mathcal{X}\mathcal{Y}} - y_i\|^2$ 。本文的目标是使用学习的方法来重现一个更好的匹配, 之后再使用这个匹配来计算刚性变换。




Figure 2. Network architecture for DCP, including the Transformer module for DCP-v2.

Deep Closest Point

初始特征

对于初始特征的提取, 本文从PointNet和DGCNN两个模型中选择了DGCNN。首先, PointNet提取的是全局特征, 而DGCNN提取的是点特征, 而本文需要的是每个点的特征来进行特征点匹配, 同时DGCNN还考虑了局部近邻的信息, 因此这里选择DGCNN, 并用实验证明了选择的正确性。

Attention

为了使模型能够适应不同任务的需要, 比如处理有机体形状和尖锐的机械物体需要的特征区别很大。因此本文使用了基于注意力的模型。 $\mathcal{F}_{\mathcal{X}}, \mathcal{F}_{\mathcal{Y}}$ 是DGCNN提取出的特征, 这里的注意力模型的任务就是学习一个函数 $\phi: \mathbb{R}^{N \times P} \times \mathbb{R}^{N \times P} \rightarrow \mathbb{R}^{N \times P}$ 。

通过这个函数, 就获得了新的特征

$$\Phi_{\mathcal{X}} = \mathcal{F}_{\mathcal{X}} + \phi(\mathcal{F}_{\mathcal{X}}, \mathcal{F}_{\mathcal{Y}}),$$

$\Phi_{\mathcal{Y}} = \mathcal{F}_{\mathcal{Y}} + \phi(\mathcal{F}_{\mathcal{Y}}, \mathcal{F}_{\mathcal{X}})$, 对这个特征再做co-attention生成最终的特征

点生成

通过特征的匹配，该模型为每个 \mathcal{X} 内的点生成一个针对于 \mathcal{Y} 内点的概率即

$$m(x_i, \mathcal{Y}) = \text{softmax}(\Phi_{\mathcal{Y}} \Phi_{x_i}^T)$$

SVD模块

首先根据概率生成一个平均匹配点 $\hat{y}_i = Y^T m(x_i, \mathcal{Y})$ ，在获得了匹配点之后，就可以按照匹配点进行SVD分解并最终得到变换矩阵。